

SEMINARIO AADECA-UBA

**“Lógica difusa, redes neuronales
y control predictivo.
Técnicas modernas de control”**

Profesora: Dra. Doris Sáez

**APUNTES III:
CONTROL PREDICTIVO NO LINEAL**

CONTROL PREDICTIVO NO LINEAL

Debido a que los procesos reales son no lineales o presentan diferentes condiciones de operación han surgido diversas estrategias de control para resolver este tema.

En particular se presentarán, a continuación, estrategias de control predictivo no lineal.

CONTROL PREDICTIVO “GAIN SCHEDULED” (Chow, 1995)

Modelo no lineal: Modelo interpolado para describir el comportamiento no lineal del proceso (Modelo discreto variante en el tiempo).

$$A(v(t), z^{-1})y(t) = B(v(t), z^{-1})u(t-1)$$

con $v(t)$ es una variable “scheduling” de la cual dependen los parámetros de los polinomios A y B .

A continuación, se presentan los pasos de la estrategia de control.

- 1.- Identificación de una familia de modelos lineales

$$A_i(z^{-1})y(t) = B_i(z^{-1})u(t-1)$$

- 2.- Derivación de una ley de control GPC para cada modelo lineal válido para un punto de operación.

$$\Delta u_i(t) = (G^T G + \lambda I)G^T(w - f)$$

- 3.- La ley de control global “Gain-scheduling” es obtenida interpolando los parámetros del controlador entre los puntos

de operación. Generalmente, los puntos de operación dependen de una variable del proceso $v(t)$.

- 4.- Para la interpolación se puede utilizar la interpolación de ganancias y ceros del proceso, obteniendo transiciones suaves en la respuesta del sistema.

Por ejemplo, la ganancia interpolada K está dada por:

$$K(v(t)) = K(v_1(t)) + (K(v_2(t)) - K(v_1(t))) \frac{v(t) - v_1(t)}{v_2(t) - v_1(t)}$$

con $v(t)$ es la variable que determina el punto de operación y $v_i(t)$ son los puntos de operación.

CONTROL PREDICTIVO CON TRANSFORMACIÓN NO LINEAL (Bosley, 1993)

- 1.- Modelo no lineal

$$\dot{x} = g(x, u)$$

- 2.- Transformación en variables de estado para convertir el sistema no lineal en un sistema lineal.
- 3.- Derivación de un controlador lineal (controlador predictivo) para el sistema lineal
- 4.- Transformación inversa para determinar la acción de control

Desventaja: Este método es sólo aplicable a ciertos sistemas no lineales donde es posible encontrar las respectivas transformaciones.

CONTROL DMC LINEAL PONDERADO (Di Marco, 1997)

- 1.- Modelo no lineal: Suma ponderada de modelos lineales para representar las diferentes zonas de operación.

$$y(t) = \sum_{i=1}^n w_i y_i(t)$$

donde n es el número de zonas de operación y $y_i(t)$ son los modelos lineales para cada zona de operación.

Las ponderaciones w_i son calculadas en función de la distancia d_i entre un punto de operación genérico (actual) $y(t)$ y un punto de operación $y_i(t)$:

$$w_i = \frac{d_i^{-1}}{\sum_{j=1}^n d_j^{-1}} \quad \text{con } d_i = |y(t) - y_i(t)| \text{ y } \sum_{i=1}^n w_i = 1$$

- 2.- Derivación de un modelo lineal en cada instante de muestreo.
- 3.- Derivación de una acción de control DMC para cada instante de muestreo.

CONTROL DMC NO LINEAL (Di Marco, 1997)

- 1.- Modelo no lineal: Modelo fenomenológico
- 2.- Derivación de un modelo lineal por linealización en cada instante de muestreo.
- 3.- Derivación de un DMC en cada instante de muestreo.

CONTROL PREDICTIVO BASADO EN MODELOS DIFUSOS

Los modelos difusos sirven para representar las no linealidades del proceso.

A continuación, se presentan las diversas estrategias de control predictivo difuso.

Cipriano & Ramos (1995)

GPC basado en modelos difusos de Takagi & Sugeno.

Modelo difuso de Takagi & Sugeno

R_i : Si $y(t-1)$ es $A1_i$ y ... y $y(t-ny)$ es A_{ny}_i y
 $u(t-1)$ es $B1_i$ y ... y $u(t-nu)$ es B_{nu}_i
entonces $y_i(t) = a_1^i y(t-1) + \dots + a_{ny}^i y(t-ny)$
 $+ b_1^i u(t-1) + \dots + b_{nu}^i u(t-nu) + c^i$

$$y(t) = \frac{\sum_{i=1}^M w_i y_i}{\sum_{i=1}^M w_i}$$

Controlador difuso

Para cada regla se deriva un controlador GPC lineal. De esta manera, el controlador difuso incluye las mismas premisas que el modelo difuso y las consecuencias están dadas por las acciones de control resultantes (GPC lineales)

R_i : Si $y(t-1)$ es $A1_i$ y ... y $y(t-ny)$ es A_{ny}_i y
 $u(t-1)$ es $B1_i$ y ... y $u(t-nu)$ es B_{nu}_i
 entonces $\Delta u_i(t) = f_i(\Delta u(t-1), \dots, y(t), y(t-1), \dots)$

con f_i es un controlador GPC lineal para la regla i .

Entonces, la acción de control GPC difusa está dada por:

$$\Delta u(t) = \frac{\sum_{i=1}^M w_i \Delta u_i(t)}{\sum_{i=1}^M w_i}$$

Desventajas

Consecuencia del modelo difuso regla R_i :

$$y_i(t) = a_1^i y(t-1) + \dots + a_{ny}^i y(t-ny) \\ + b_1^i u(t-1) + \dots + b_{nu}^i u(t-nu) + c^i$$

Para cada regla se minimiza la siguiente función objetivo:


$$J_i = \sum_{j=N_1}^{N_2} [w(t+j) - \hat{y}_i(t+j/t)]^2 + \sum_{j=1}^{N_u} \lambda(j) [\Delta u(t+j-1)]^2$$

donde $\hat{y}_i(t+j/t)$ es la predicción a j pasos con el modelo lineal de la regla i .

Se debiese minimizar la siguiente función objetivo:

$$J = \sum_{j=N_1}^{N_2} [w(t+j) - \hat{y}(t+j/t)]^2 + \sum_{j=1}^{N_u} \lambda(j) [\Delta u(t+j-1)]^2$$

donde $\hat{y}(t+j/t)$ es la predicción a j pasos con el modelo difuso completo.



Sin embargo, la solución del GPC difuso (Cipriano & Ramos, 1995) es una buena aproximación y es de fácil y rápida implementación.

Roubos (1998)

Controlador predictivo basado en la linealización del modelo difuso de Takagi & Sugeno

Modelo difuso de Takagi & Sugeno

R_i : Si $x_1(t)$ es A_{1i} y ... y $x_n(t)$ es A_{ni}

entonces $x^i(t+1) = A^i x(t) + B^i u(t) + C^i$

$$x(t+1) = \sum_{i=1}^M w_i x^i(t+1)$$

con w_i es el grado de activación normalizado.

1.- Modelo lineal variante en el tiempo equivalente

$$x(t+1) = A(t)x(t) + B(t)u(t) + C(t)$$

con
$$A(t) = \sum_{i=1}^n w_i(t) A^i$$

$$B(t) = \sum_{i=1}^n w_i(t) B^i$$

$$C(t) = \sum_{i=1}^n w_i(t) C^i$$

2.- En cada instante o período de muestreo, se deriva un modelo lineal, evaluando las premisas del modelo difuso o grados de activación.

3.- Para cada modelo lineal resultante se diseña un controlador predictivo lineal.

4.- En el siguiente instante, se actualiza el modelo lineal

Ventajas: Fácil y rápida implementación.

Desventajas: Solución sub-óptima

Cipriano & Sáez (1996)

Modelo difuso de Takagi & Sugeno

R_i : Si $y(t-1)$ es A_{1i} y ... y $y(t-ny)$ es A_{ni} y
 $u(t-1)$ es B_{1i} y ... y $u(t-nu)$ es B_{nu_i}

$$\text{entonces } A_i(z^{-1})y_i(t) = B_i(z^{-1})u(t-1) + \frac{e_i(t)}{\Delta}$$

Predictor difuso

Se deriva la predicción lineal para cada modelo lineal de cada regla:

R_i : Si $y(t-1)$ es A_{1i} y ... y $y(t-ny)$ es A_{ni} y
 $u(t-1)$ es B_{1i} y ... y $u(t-nu)$ es B_{nu_i}
entonces $\hat{y}_i = G_i \Delta u + f_i$

donde \hat{y}_i es el vector de predicciones

$$\hat{y}_i = [\hat{y}_i(t+N_1), \dots, \hat{y}_i(t+N_2)]^T$$

Entonces, la predicción global está dada por:

$$\hat{y} = \frac{\sum_{i=1}^M w_i(t) \hat{y}_i}{\sum_{i=1}^M w_i(t)} = \frac{\sum_{i=1}^M w_i(t) [G_i \Delta u + f_i]}{\sum_{i=1}^M w_i(t)}$$

con $w_i(t)$ es el grado de activación y M es el número de reglas.

Controlador difuso

$$J = (\mathbf{w} - \hat{\mathbf{y}})^T (\mathbf{w} - \hat{\mathbf{y}}) + \lambda \Delta \mathbf{u}^T \Delta \mathbf{u}$$

con \mathbf{w} es el vector de referencias futuras, $\hat{\mathbf{y}}$ es el vector de predicciones y $\Delta \mathbf{u}$ es el vector de acciones de control futuras.

Sustituyendo el predictor difuso en la función objetivo se tiene:

$$J = \left(\mathbf{w} - \frac{\sum_{i=1}^M \mathbf{w}_i(t) [\mathbf{G}_i \Delta \mathbf{u} + \mathbf{f}_i]}{\sum_{i=1}^M \mathbf{w}_i(t)} \right)^T \left(\mathbf{w} - \frac{\sum_{i=1}^M \mathbf{w}_i(t) [\mathbf{G}_i \Delta \mathbf{u} + \mathbf{f}_i]}{\sum_{i=1}^M \mathbf{w}_i(t)} \right) + \lambda \Delta \mathbf{u}^T \Delta \mathbf{u}$$

$$\underset{\Delta \mathbf{u}}{\text{Min}} J$$

$$\Delta \mathbf{u} = (\mathbf{G}^T \mathbf{G} + \lambda \mathbf{I})^{-1} \mathbf{G}^T (\mathbf{w} - \mathbf{f})$$

con

$$\mathbf{G} = \frac{\sum_{i=1}^M \mathbf{w}_i(t) \mathbf{G}_i}{\sum_{i=1}^M \mathbf{w}_i(t)} \quad \mathbf{f} = \frac{\sum_{i=1}^M \mathbf{w}_i(t) \mathbf{f}_i}{\sum_{i=1}^M \mathbf{w}_i(t)}$$

Ventajas: Rápida y fácil implementación

Desventajas: Sólo es una mejor aproximación del óptimo global.

Espinosa (1999)

Modelo difuso de Takagi & Sugeno

R_i : Si $y(t-1)$ es A_{1i} y ... y $y(t-ny)$ es A_{ni} y
 $u(t-1)$ es B_{1i} y ... y $u(t-nu)$ es B_{ni}

entonces $A_i(z^{-1})y_i(t) = B_i(z^{-1})u(t-1) + \frac{e_i(t)}{\Delta}$

Predictor difuso

$$\hat{y}(t+j) = \hat{y}_{\text{libre}}(t+j) + \hat{y}_{\text{forzado}}(t+j)$$

donde $\hat{y}_{\text{libre}}(t+j)$ depende de las entradas y salidas pasadas

$\hat{y}_{\text{forzado}}(t+j)$ depende de las acciones de control futuras

En este caso, se tiene:

$$\hat{y}(t+j) = G\Delta u + \hat{y}_{\text{libre}}(t+j)$$

$$\text{donde } \hat{y}_{\text{forzado}}(t+j) = G\Delta u = \sum_{i=1}^{j-1} \Delta u(t+j-i-1)$$

y $\hat{y}_{\text{libre}}(t+j)$ es calculado por la simulación del modelo difuso considerando las acciones de control futuras constantes e iguales a $u(t-1)$.

Luego, la acción de control está dada por:

$$\Delta u = (G^T G + \lambda I)^{-1} G^T (w - \hat{y}_{\text{libre}})$$

donde

$$\hat{y}_{\text{libre}}(t+j) = f(y(t+j-1), \dots, y(t+j-ny), \\ u(t+j-1), \dots, u(t+j-nu))$$

Babuska (1999), Espinosa & Vandewalle (1998, 1999) y Hadjili & Wertz (1999)

Linealización multipaso

El modelo difuso es primero linealizado en el instante actual t . Entonces, la acción de control actual $u(t+j)$ sirve para predecir $\hat{y}(t+j)$ y el modelo no lineal es de nuevo linealizado entorno al futuro punto de operación. Este procedimiento se repite hasta $t+N_2$

Modelo difuso

R_i : Si $y(t-1)$ es $A1_i$ y ... y $y(t-ny)$ es Any_i y
 $u(t-1)$ es $B1_i$ y ... y $u(t-nu)$ es Bnu_i
 entonces $y_i(t) = a_1^i y(t-1) + \dots + a_{ny}^i y(t-ny) \\ + b_1^i u(t-1) + \dots + b_{nu}^i u(t-nu) + c^i$

$$y(t) = \sum_{\ell=1}^{ny} \bar{a}_{\ell} y(t-\ell) + \sum_{\ell=1}^{nb} \bar{b}_{\ell} u(t-\ell) + \bar{c}(t)$$

con
$$\bar{a}_{\ell}(t) = \sum_{i=1}^M w_i(t) a_{\ell}^i$$

$$\bar{b}_{\ell}(t) = \sum_{i=1}^M w_i(t) b_{\ell}^i$$

$$\bar{c}_\ell(t) = \sum_{i=1}^M w_i(t) c^i$$

Predictor difuso multipaso

$$\begin{aligned} \hat{y}(t+j) &= \sum_{\ell=1}^{ny} \bar{a}_\ell(t+j) y(t+j-\ell) \\ &\quad + \sum_{\ell=1}^{nb} \bar{b}_\ell(t+j) u(t+j-\ell) + \bar{c}(t+j) \\ \text{con } \bar{a}_\ell(t+j) &= \sum_{i=1}^M w_i(t+j) a_\ell^i \\ \bar{b}_\ell(t+j) &= \sum_{i=1}^M w_i(t+j) b_\ell^i \\ \bar{c}_\ell(t+j) &= \sum_{i=1}^M w_i(t+j) c^i \\ w_i(t+j) &= f(\hat{y}(t+j-1), \dots, \hat{y}(t+j-ny), \\ &\quad u(t+j-1), \dots, u(t+j-nu)) = 0 \end{aligned}$$

En este caso, el predictor difuso utiliza la predicción $\hat{y}(t+1)$ para obtener $\hat{y}(t+2)$ y este procedimiento se repite hasta $t+N_2$.

Solución de controlador difuso

Método del Lagrangiano y condiciones de Kuhn-Tucker (Solución numérica)

Ventajas: Mejor aproximación del modelo no lineal, especialmente útil para horizontes de predicción largos.

Desventajas: Mayor esfuerzo computacional.